

Universidad San Carlos de Guatemala
Facultad de ingeniería.
Ingeniería en ciencias y sistemas



Práctica 1:

ETL con Python: de dataset crudo a
tabla relacional lista para análisis

PONDERACIÓN: 10 pts

 **Tiempo estimado: 16 hrs**

Índice

1. MARCO FORMATIVO	3
1.1. Valor	3
1.2. Competencia(s)	3
1.3. Objetivo SMART	3
2. Enunciado de la Práctica	4
2.1 Descripción del problema a resolver	4
2.2 Alcance de la práctica	4
2.3 Requerimientos técnicos	5
3. Entregables	5
4. Material de apoyo	6
5. Recursos y herramientas a utilizar	6
6. Cronograma	7
7. Rúbrica de Calificación	7
7.1 Requisitos para optar a la calificación	7
7.2 Resumen de Puntuaciones	8
7.3 Comentarios Generales	8
Detalle de la Calificación	9

1. MARCO FORMATIVO

1.1. Valor

Nombre del valor	¿Cómo se aplica en tu laboratorio?
Responsabilidad académica y técnica	Cumplimiento riguroso de los lineamientos del proceso ETL, documentación del avance y entrega funcional del modelo implementado.

1.2. Competencia(s)

Tipo de Competencia	Generales y específica
Competencia General	• Aplica principios de ingeniería y ciencias de la computación integrando fundamentos teóricos y prácticos en la formulación y resolución adecuada de problemas de información • Comunica resultados de análisis de datos utilizando diversos formatos y lenguajes dirigidos a diferentes audiencias profesionales y sociales
Competencia Específica	Analiza datos estructurados y no estructurados utilizando procesos de preparación, transformación y exploración para identificar patrones, relaciones y oportunidades de mejora

1.3. Objetivo SMART

SMART	Definición	Objetivo redactado
Específico (¿Qué?)	El objetivo es concreto y tangible.	Desarrollar un proceso ETL completo en Python que extraiga, transforme y cargue datos desde una fuente proporcionada hacia un modelo de inteligencia de negocios implementado en SQL Server.
Medible (¿Cuánto?)	El objetivo tiene una medida objetiva de éxito.	El objetivo se considerará cumplido al contar con una aplicación funcional que ejecute correctamente las tres fases del proceso ETL y cargue los datos en el modelo definido, verificando su contenido mediante consultas analíticas.
Alcanzable (¿Cómo?)	El objetivo debe ser posible con los recursos disponibles.	El desarrollo se realizará con Python y SQL Server, herramientas accesibles para los estudiantes, aplicando los conocimientos adquiridos sobre ETL y modelado de datos.
Realista (¿Para qué?)	El objetivo contribuye a metas más amplias.	El objetivo es fomentar la aplicación práctica de conceptos de ingeniería de datos, integrando análisis, modelado y procesamiento para soportar decisiones empresariales.
A Tiempo (¿Cuándo?)	El objetivo tiene fecha límite o mejor aún un cronograma de hitos de progreso	La práctica deberá completarse y entregarse según las fechas establecidas en el cronograma del curso del semestre.

2. Enunciado de la Práctica

2.1 Descripción del problema a resolver

Las organizaciones actuales generan grandes volúmenes de información provenientes de diversas fuentes. Para aprovechar estos datos de forma estratégica, se requiere implementar un proceso de integración y análisis estructurado.

En esta práctica, el estudiante deberá **diseñar e implementar un proceso ETL (Extracción, Transformación y Carga)** utilizando Python y SQL Server.

El escenario simula el manejo de información proveniente de registros de vuelos, donde los datos se encuentran en múltiples fuentes heterogéneas y deben ser estandarizados para su análisis.

El objetivo es construir un modelo multidimensional de inteligencia de negocios que permita ejecutar consultas analíticas y generar información útil para la toma de decisiones.

2.2 Alcance de la práctica

Obligatorio:

- Implementar una aplicación en **Python** que ejecute las tres fases del proceso ETL: extracción, transformación y carga.
- Crear un **modelo multidimensional de datos en SQL Server** que soporte consultas analíticas, donde al menos una de las dimensiones sea de tipo 2.
- Desarrollar consultas SQL que permitan validar la correcta carga de datos y generar indicadores relevantes (por ejemplo, número de vuelos, destinos más frecuentes, distribución por género, etc.).
- Documentar el proceso con diagramas y explicación técnica del modelo multidimensional implementado.
- Entregar un repositorio con la estructura establecida para el curso y un **README.md** con detalles del desarrollo y resultados.

Opcional / Recomendado:

- Incorporar manejo de excepciones y registro de errores en la aplicación.
- Implementar visualizaciones básicas con herramientas externas (Power BI, Tableau o Python con Matplotlib).
- Optimizar las consultas SQL para mejorar el rendimiento del modelo multidimensional.

2.3 Requerimientos técnicos

- Lenguaje de programación: **Python (versión 3.10 o superior)**
- Motor de base de datos: **Microsoft SQL Server**
- Librerías sugeridas: **pandas, pyodbc, sqlalchemy, datetime**
- Conocimiento y aplicación del **proceso ETL**: extracción de archivos fuente, transformación (limpieza, homologación y estandarización), y carga en tablas destino.
- Diseño e implementación de un **modelo multidimensional o relacional** para inteligencia de negocios.
- Uso de **consultas SQL analíticas** (agrupaciones, conteos, filtrado, etc.) para validación y obtención de resultados.
- Organización del proyecto en un repositorio con nombre **SS22S2026_#G**, carpeta **Practica1**, y documentación técnica en formato Markdown.

3. Entregables

Tipo	Descripción
Aplicación ETL en Python	Script funcional que realice la extracción, transformación y carga de los datos desde las fuentes proporcionadas hacia el modelo multidimensional de base de datos.
Script de Base de Datos (SQL Server)	Archivo con las sentencias SQL necesarias para la creación de las tablas, relaciones y estructuras del modelo multidimensional de inteligencia de negocios.
Modelo de Datos	Diagrama que muestre las entidades, atributos y relaciones del modelo multidimensional implementado, con enfoque relacional o dimensional según corresponda.
Consultas Analíticas	Archivo con las consultas SQL utilizadas para validar la carga de datos y obtener información relevante (conteos, top 5, distribuciones, etc.).
Documentación Técnica	Documento en formato PDF o README.md que incluya descripción del proceso ETL, diseño del modelo multidimensional, pasos de ejecución y resultados obtenidos.
Repositorio del Curso	Carpeta Practica1 dentro del repositorio SS22S2026_G# , con todos los archivos organizados y nombrados conforme a los lineamientos del laboratorio.

4. Material de apoyo

- Documentación oficial de Python <https://docs.python.org/3/>
- Tutorial de procesos ETL con Python y Pandas <https://realpython.com/python-etl/>
- Documentación de Pandas <https://pandas.pydata.org/docs/>
- Guía de conexión Python–SQL Server (pyodbc / SQLAlchemy) <https://learn.microsoft.com/sql/connect/python/>
- Fundamentos de SQL Server y consultas analíticas <https://learn.microsoft.com/sql/t-sql/>
- Introducción al modelado dimensional <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/>

5. Recursos y herramientas a utilizar

Software:

- Python 3.10 o superior
- Microsoft SQL Server
- Visual Studio Code o PyCharm (IDE recomendado)

Plataformas:

- GitHub (para repositorio y control de versiones)
- UEDI (para entrega oficial de la práctica)

Lecturas recomendadas:

- Documentación oficial de Python y Pandas
- Guías de modelado dimensional y relacional
- Manual de SQL Server: creación de bases de datos y consultas analíticas
- Artículos técnicos sobre procesos ETL y gobierno de datos

6. Cronograma

Tipo	Fecha Inicio	Fecha Fin
Asignación de Práctica	Semana 3	Semana 3
Elaboración	Semana 3	Semana 5
Calificación	Semana 5	Semana 5

7. Rúbrica de Calificación

7.1 Requisitos para optar a la calificación

Tema	Descripción	Cumple (Sí/No)
Cumplimiento de la tecnología establecida	El proceso ETL debe desarrollarse en Python y el modelo multidimensional de inteligencia de negocios implementarse en SQL Server .	
Uso de herramientas requeridas	Se debe evidenciar el uso de librerías de Python (pandas, pyodbc o SQLAlchemy), conexión a base de datos y ejecución de consultas SQL.	
Gestión y entregas de práctica	El repositorio SS22S2026_G# debe contener la carpeta Practica1 con código fuente, scripts SQL, documentación y README.md según lineamientos.	
Documentación obligatoria	Incluir documentación técnica en formato PDF o Markdown que describa el proceso ETL, el modelo multidimensional de datos y los resultados obtenidos.	
Pruebas y funcionalidad mínima	La aplicación debe ejecutar correctamente la extracción, transformación y carga de datos, generar el modelo multidimensional y validar resultados mediante consultas analíticas.	

7.2 Resumen de Puntuaciones

Área	Puntos Totales	Puntos Obtenidos
1. Habilidades		
Desarrollo del proceso ETL (estructura y ejecución correcta)	15	
Documentación técnica (claridad, orden y coherencia)	15	
Cumplimiento de entregables (formato, nomenclatura y organización del repositorio)	10	
Sub-Total Habilidades	40	
2. Conocimientos		
Modelo de datos en SQL Server (estructura, integridad y relaciones correctas)	25	
Consultas analíticas (validación de carga, indicadores y resultados esperados)	35	
Sub-Total Conocimientos	60	
TOTAL	100	

7.3 Comentarios Generales

Detalle de la Calificación

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100%–61%)	Necesita mejorar (60%–0%)	Punteo obtenido
1	Habilidades	40			
1.1	Desarrollo del proceso ETL	15	Implementa correctamente las fases de extracción, transformación y carga en Python. El código es funcional, estructurado y sin errores críticos.	No completa las tres fases del proceso ETL o presenta fallos que impiden su ejecución.	
	Rango del punteo:		15/15–9	15/8–0	
1.2	Documentación técnica	15	La documentación describe el proceso ETL, el modelo multidimensional de datos y resultados con claridad, formato ordenado y lenguaje técnico adecuado.	La documentación es incompleta, desorganizada o carente de explicación técnica.	
	Rango del punteo:		15/15–9	15/8–0	
1.3	Cumplimiento de entregables	10	Entrega completa con repositorio estructurado, archivos correctamente nombrados y README detallado.	Faltan archivos, el repositorio no sigue el formato indicado o hay errores en la presentación.	
	Rango del punteo:		10/10–6	10/5–0	

Sub-total Habilidades		40			
2	Conocimientos	60			
2.1	Modelo de datos en SQL Server	25	El modelo multidimensional relacional o dimensional está correctamente diseñado e implementado, con integridad referencial y relaciones coherentes.	El modelo multidimensional presenta errores de diseño, relaciones incorrectas o no ejecuta correctamente en SQL Server.	
	Rango del punteo:		25–15	14–0	
2.2	Consultas analíticas	35	Las consultas SQL validan la carga de datos y generan resultados analíticos correctos (conteos, indicadores, top 5, etc.).	Las consultas son incompletas, incorrectas o no evidencian comprensión del modelo multidimensional .	
	Rango del punteo:		35–21	20–0	
Sub-total Conocimientos		60			
Total General		100			