

Universidad San Carlos de Guatemala

Facultad de ingeniería.

Ingeniería en ciencias y sistemas



Proyecto 1:

Implementación de un flujo moderno
de datos con Python, Apache Airflow,
dbt y PostgreSQL

PONDERACIÓN: 25 pts

 **Tiempo estimado: 24 hrs**

Índice

1. MARCO FORMATIVO	3
1.1. Valor	3
1.2. Competencia(s)	3
1.3. Objetivo SMART	4
2. Resumen Ejecutivo	5
3. Enunciado del Proyecto	5
3.1 Descripción del problema a resolver	5
3.2 Alcance del proyecto	5
3.3 Requerimientos técnicos	6
3.4 Entregables	6
4. Material de apoyo	7
5. Metodología	7
6. Recursos y herramientas a utilizar	8
7. Desarrollo de Habilidades Blandas	8
8. Cronograma	9
9. Rúbrica de Calificación	9
9.1 Requisitos para optar a la calificación	9
9.2 Resumen de Puntuaciones	10
9.3 Comentarios Generales	10
9.4 Detalle de la Calificación	11

1. MARCO FORMATIVO

1.1. Valor

Nombre del valor	¿Cómo se aplica en tu laboratorio?
Responsabilidad técnica, colaboración y compromiso profesional	Cumplimiento de las fases del flujo de datos con rigor técnico, trabajo colaborativo en grupo, entrega puntual y documentación completa que refleje el diseño, implementación y validación de Python, Airflow, PostgreSQL y dbt.

1.2. Competencia(s)

Tipo de Competencia	Generales y específicas
Competencia General	● Aplica principios de ingeniería y ciencias de la computación integrando fundamentos teóricos y prácticos en la formulación y resolución adecuada de problemas de información. ● Crea modelos analíticos y soluciones de interpretación aplicando metodologías de integración, orquestación y ciclo de vida de datos con el fin de resolver problemas complejos en contextos organizacionales.
Competencia Específica	Analiza, integra y transforma datos estructurados mediante procesos de extracción, carga, orquestación, modelado analítico y validación con Python, Airflow, PostgreSQL y dbt para identificar patrones, relaciones y oportunidades de mejora.

1.3. Objetivo SMART

SMART	Definición	Objetivo redactado
Específico (¿Qué?)	El objetivo es concreto y tangible.	Diseñar e implementar en grupo una solución completa de datos para la empresa SG-Food, desarrollando procesos de extracción y carga con Python, orquestación con Apache Airflow, un Data Warehouse en PostgreSQL y modelos analíticos con dbt para el análisis de ventas e inventarios.
Medible (¿Cuánto?)	El objetivo tiene una medida objetiva de éxito.	El proyecto se considerará cumplido al entregar un sistema funcional con DAGs de Airflow operativos, carga de datos raw en PostgreSQL, modelos dbt ejecutados, pruebas de calidad aprobadas y documentación técnica que describa las fases y resultados.
Alcanzable (¿Cómo?)	El objetivo debe ser posible con los recursos disponibles.	El objetivo puede lograrse utilizando herramientas abiertas y ampliamente utilizadas en ingeniería de datos: Python, Apache Airflow, PostgreSQL y dbt Core, aplicando conocimientos de extracción, carga, modelado dimensional, validación y automatización.
Realista (¿Para qué?)	El objetivo contribuye a metas más amplias.	Fortalece las competencias prácticas en arquitectura de datos, orquestación, modelado analítico y calidad de datos, alineadas con necesidades reales de organizaciones que buscan pipelines reproducibles y mantenibles.
A Tiempo (¿Cuándo?)	El objetivo tiene fecha límite o mejor aún un cronograma de hitos de progreso	Debe completarse conforme al cronograma del curso del semestre 2026-1, dentro del período asignado para el desarrollo del proyecto final.

2. Resumen Ejecutivo

Este proyecto, desarrollado en el curso Seminario de Sistemas 2, tiene como propósito implementar una solución completa de integración, transformación y modelado analítico de datos utilizando Python, Apache Airflow, dbt y PostgreSQL. El problema identificado es la necesidad de automatizar la extracción desde una fuente transaccional, cargar datos crudos en un Data Warehouse, transformar la información de forma controlada y construir modelos analíticos confiables. La propuesta consiste en desarrollar un flujo ELT orquestado con Airflow, procesos de extracción y carga con Python, un Data Warehouse en PostgreSQL y modelos dbt para staging, dimensiones, hechos, pruebas y documentación. El proyecto deberá desarrollarse en grupo y permitirá aplicar competencias en ingeniería de datos, modelado dimensional, automatización, calidad de datos y documentación técnica profesional.

3. Enunciado del Proyecto

3.1 Descripción del problema a resolver

SG-Food es una empresa dedicada a la distribución y comercialización de productos de diversas marcas y categorías. Actualmente enfrenta dificultades para integrar y analizar sus datos debido a procesos manuales, poca trazabilidad en las transformaciones, ausencia de pruebas de calidad y dependencia directa de la base de datos transaccional para la generación de reportes.

Los grupos deberán desarrollar una solución moderna de datos que permita automatizar el flujo desde una base transaccional hacia un Data Warehouse en PostgreSQL. La solución debe utilizar Python para la extracción y carga de datos, Apache Airflow para la orquestación del pipeline y dbt para transformar, documentar y validar los modelos analíticos. El objetivo es disponer de una arquitectura reproducible que integre datos crudos, construya dimensiones y hechos, ejecute pruebas de calidad y facilite consultas analíticas para la toma de decisiones oportunas.

3.2 Alcance del proyecto

Obligatorio:

- Implementar un proceso de extracción y carga utilizando Python.
- Orquestar el flujo completo mediante Apache Airflow, incluyendo tareas de carga, ejecución de dbt y validaciones.
- Desarrollar un Data Warehouse en PostgreSQL con modelo dimensional basado en tablas de hechos y dimensiones.
- Implementar modelos dbt para staging, intermediate y marts, incluyendo sources, refs, materializaciones y pruebas de calidad.
- Validar y documentar el flujo completo: extracción, carga raw, modelos dbt, Data Warehouse analítico y consultas de validación.

Opcional / Recomendado:

- Incluir ejecución programada del DAG de Airflow y parametrización de conexiones mediante variables o archivos de configuración.
- Implementar validaciones adicionales, manejo de errores y registros de ejecución dentro del flujo de Airflow y dbt.
- Conectar los modelos analíticos de PostgreSQL con una herramienta de visualización como Power BI, Metabase o Superset.

3.3 Requerimientos técnicos

- **Herramientas de desarrollo:** Python, Apache Airflow, dbt Core y PostgreSQL.
- **Plataforma de datos:** PostgreSQL como Data Warehouse y schemas separados para raw, staging y marts.
- **Fuentes de datos:** al menos una base de datos transaccional y archivos delimitados o CSV cargados mediante Python.
- **Procesos requeridos:** extracción, carga, orquestación, transformación con dbt, pruebas de calidad y validación de consultas analíticas.
- **Modelo de datos:** esquema dimensional o estrella en PostgreSQL, construido con dbt mediante dimensiones, hechos, relaciones y materializaciones consistentes.
- **Conocimientos aplicados:** Python, Airflow, ELT, Data Warehouse, dbt, modelado dimensional, pruebas de calidad y documentación técnica.

3.4 Entregables

Tipo	Descripción
Proyecto de Python, Airflow y dbt	Solución completa con scripts Python, DAGs de Airflow, proyecto dbt y configuración necesaria para ejecutar la extracción, carga, transformación, validación y documentación del flujo de datos.
Script DDL del Data Warehouse	Archivo con las sentencias SQL para la creación de schemas, tablas raw si aplica, tablas de hechos, dimensiones, relaciones y claves necesarias para el Data Warehouse implementado en PostgreSQL.

Scripts de validación y consultas analíticas	Archivos SQL, pruebas dbt y consultas analíticas utilizadas para comprobar la correcta carga de datos, validar la integridad de la información y verificar resultados de los modelos analíticos.
Documentación técnica	Documento o archivo README que incluya el nombre del proyecto, integrantes de la pareja, descripción del pipeline, DAG de Airflow, modelo del Data Warehouse, estructura del proyecto dbt, justificación de diseño y manual de implementación.
Repositorio del curso	Carpeta Proyecto1 dentro del repositorio SS22S2026_#GRUPO, que contenga todos los archivos del proyecto, documentación y scripts organizados conforme a los lineamientos del laboratorio. En el README deben indicarse ambos integrantes de la pareja.

4. Material de apoyo

- Documentación oficial de Apache Airflow <https://airflow.apache.org/docs/>
- Documentación oficial de dbt <https://docs.getdbt.com/>
- Documentación oficial de PostgreSQL <https://www.postgresql.org/docs/>
- Guía de instalación de dbt para PostgreSQL
<https://docs.getdbt.com/docs/core/connect-data-platform/postgres-setup>

5. Metodología

- 1. Investigación preliminar**

Analizar el contexto de la empresa SG-Food y revisar los conceptos clave de ingeniería de datos, Data Warehouse, ELT, orquestación con Airflow y modelado analítico con dbt. Identificar las fuentes de datos y definir las estructuras necesarias para la carga raw y la transformación analítica.
- 2. Diseño del sistema de datos**

Definir la arquitectura general del sistema. Diseñar el flujo de extracción y carga con Python, el DAG de Airflow, la estructura del Data Warehouse en PostgreSQL y el modelo dimensional que será construido con dbt, incluyendo sources, staging, dimensiones, hechos, pruebas y documentación.

3. Desarrollo del proceso de extracción y carga

Implementar con Python los procesos de conexión a la fuente, extracción de datos, limpieza técnica mínima y carga hacia el schema raw de PostgreSQL. Integrar estas tareas en Apache Airflow para asegurar ejecución ordenada, trazabilidad y control de errores.

4. Implementación del Data Warehouse y modelos dbt

Construir los modelos dbt necesarios para transformar los datos raw en staging, intermediate y marts. Crear tablas de dimensiones y hechos, aplicar llaves, relaciones, materializaciones, pruebas y documentación automática del proyecto.

5. Validación y pruebas

Ejecutar pruebas funcionales para verificar conteos de registros, integridad referencial, unicidad, valores nulos, consistencia de los modelos dbt y resultados de consultas analíticas. Documentar los resultados obtenidos y realizar los ajustes necesarios.

6. Documentación y entrega final

Elaborar un documento técnico que describa todas las fases del proyecto, incluyendo arquitectura, DAG de Airflow, scripts Python, estructura de PostgreSQL, modelos dbt, pruebas, consultas de validación y manual de implementación. Subir al repositorio correspondiente todos los archivos requeridos en la carpeta Proyecto1.

6. Recursos y herramientas a utilizar

Software:

- Python 3.x
- Apache Airflow
- PostgreSQL y dbt Core con adapter dbt-postgres

Plataformas:

- GitHub (para repositorio del proyecto y control de versiones)
- UEDI (para entrega oficial del proyecto)

Lenguajes y tecnologías:

- Python (para extracción, carga y scripts auxiliares)
- Apache Airflow (para orquestación del pipeline)
- SQL y dbt (para modelado analítico, pruebas, documentación y materializaciones)

Lecturas recomendadas:

- Documentación de Apache Airflow
- Documentación de dbt Core y dbt-postgres
- Guías de modelado dimensional, fuentes, pruebas y materializaciones en dbt

- Artículos sobre validación, observabilidad, calidad de datos y buenas prácticas ELT

7. Desarrollo de Habilidades Blandas

En este proyecto en grupos se promueven competencias transversales orientadas al desempeño profesional colaborativo:

- **Coordinación del equipo:** Planificación eficiente de tareas, distribución equilibrada del trabajo, seguimiento de avances y cumplimiento de plazos según el cronograma.
- **Responsabilidad compartida:** Ejecución de cada etapa del flujo de datos con rigor técnico, comunicación constante y compromiso con la calidad de los resultados.
- **Comunicación y reflexión crítica:** Documentación de decisiones, análisis del desempeño de la pareja, identificación de áreas de mejora y valoración del aprendizaje adquirido durante el desarrollo del proyecto.

8. Cronograma

Tipo	Fecha Inicio	Fecha Fin
Asignación de Proyecto	Semana 7	Semana 7
Elaboración	Semana 8	Semana 10
Calificación	Semana 10	Semana 10

9. Rúbrica de Calificación

9.1 Requisitos para optar a la calificación

Tema	Descripción	Cumple (Sí/No)
Cumplimiento de la tecnología establecida	El desarrollo debe realizarse utilizando Python, Apache Airflow, PostgreSQL y dbt como componentes obligatorios del flujo completo.	

Uso de herramientas requeridas	Se debe evidenciar el uso de scripts Python funcionales, DAGs de Airflow, carga en PostgreSQL, implementación de modelos dbt, pruebas de calidad y validación mediante consultas SQL.	
Gestión y entregas del proyecto	El repositorio SS22S2026_#GRUPO debe contener la carpeta Proyecto1 con todos los archivos: scripts Python, DAGs de Airflow, proyecto dbt, scripts SQL, documentación técnica y evidencia de ejecución. El trabajo debe realizarse en grupos.	
Documentación obligatoria	Debe incluir un documento o README con la descripción del proceso de extracción y carga, el Data Warehouse, los modelos dbt implementados, la justificación del diseño, integrantes de la pareja y un manual de implementación.	
Pruebas y funcionalidad mínima	El sistema debe ejecutar correctamente el DAG de Airflow, cargar datos desde las fuentes establecidas, ejecutar modelos dbt, correr pruebas de calidad y permitir la validación de resultados mediante consultas analíticas.	

9.2 Resumen de Puntuaciones

Área	Puntos Totales	Puntos Obtenidos
1. Habilidades		
Desarrollo del flujo de extracción y carga con Python y orquestación con Airflow	20	
Documentación técnica y manual de implementación	10	
Cumplimiento de entregables, trabajo en grupo y organización del repositorio	10	

Sub-Total Habilidades	40	
2. Conocimientos		
Diseño e implementación del Data Warehouse en PostgreSQL y modelos analíticos en dbt	30	
Integración de fuentes, pruebas dbt y validación del flujo completo	30	
Sub-Total Conocimientos	60	
TOTAL GENERAL	100	

9.3 Comentarios Generales

—

—

—

9.4 Detalle de la Calificación

No.	Criterio de evaluación	Punteo máximo	Satisfactorio (100 % – 61 %)	Necesita mejorar (60 % – 0 %)	Punteo obtenido
1	Habilidades	40			
1.1	Desarrollo del flujo con Python y Airflow	20	Implementa correctamente las fases de extracción, carga y orquestación con Python y Apache Airflow, incluyendo DAGs funcionales, dependencias, manejo básico de errores y carga hacia PostgreSQL.	El flujo de extracción, carga u orquestación no está completo o presenta fallos que impiden la carga y validación de los datos.	
	Rango del punteo:		20 – 12	11 – 0	
1.2	Documentación técnica y manual de implementación	10	Incluye descripción del pipeline, estructura de PostgreSQL, proyecto dbt, DAGs, configuraciones, integrantes de la pareja y pasos de ejecución de forma clara y profesional.	La documentación es incompleta, poco clara o carece de explicaciones sobre el pipeline, el Data Warehouse, Airflow, dbt o la implementación realizada.	
	Rango del punteo:		10 – 6	5 – 0	
1.3	Cumplimiento de entregables y repositorio	10	El repositorio contiene todos los archivos organizados (scripts Python, DAGs de Airflow, proyecto dbt, scripts SQL y documentación) siguiendo la estructura solicitada y evidenciando trabajo en grupo.	Faltan archivos, la estructura es incorrecta, no se siguen los lineamientos de entrega o no se evidencia el trabajo en grupo.	

	Rango del punteo:		10 – 6	5 – 0	
Sub-total Habilidades		40			
2	Conocimientos	60			
2.1	Diseño e implementación del Data Warehouse y modelos dbt	30	El modelo dimensional en PostgreSQL y los modelos dbt están correctamente diseñados e implementados, con sources, refs, materializaciones, dimensiones, hechos, relaciones y pruebas coherentes.	El Data Warehouse o los modelos dbt presentan errores en relaciones, materializaciones, pruebas o no ejecutan correctamente sobre PostgreSQL.	
	Rango del punteo:		30 – 18	17 – 0	
2.2	Integración de fuentes, pruebas y validación del flujo completo	30	Integra de forma exitosa las fuentes de datos, carga el schema raw, ejecuta el DAG de Airflow, construye modelos dbt y valida los resultados mediante pruebas y consultas analíticas.	No logra integrar todas las fuentes, completar el flujo, ejecutar las pruebas o validar adecuadamente la carga y los modelos analíticos.	
	Rango del punteo:		30 – 18	17 – 0	
Sub-total Conocimientos		60			
Total General		100			

